연구 초고 · Preprint draft · 2026-10-19

나를 대신해 판단하는 아바타: 일치(sync)를 어떻게 만들고 어떻게 잴 것인가

A Judgment-Delegating Personal Avatar: How to Build and How to Measure Agreement with One's Own Decisions

허진구 (Jingu Heo)

독립 연구 · Mental Avatar 프로젝트

> 이 원고는 연구 설계와 예비 관찰을 담은 초고다. 핵심 지표인 본인 판단과의 일치(sync)는 **아직 측정하지 않았다.** 측정하지 않은 것은 결과로 쓰지 않았고, 모든 상태 표시는 "측정됨 / 구현됨(미측정) / 설계만 / 미착수"로 구분했다.

초록

대규모 언어모델(LLM)로 특정 개인을 모사하는 디지털 트윈 연구는 인터뷰·설문[1]이나 장기 메시지[2,3]를 입력으로 삼아 본인 응답의 재현 정도를 보고해 왔다. 그러나 평가는 평균 효과나 설문 문항 중심이고 개인 수준 예측은 약하며[5,6], 그럴듯한 대화가 연속적인 판단 재현을 뜻하지 않고[10], 기억 회수·의견 일관성·문체는 하나의 점수로 합치기 어렵다[11]. 무엇보다 "이 사람이 무엇을 우선하고, 어떤 예외를 두며, 어디서 판단을 넘기는가"라는 **판단 정책**을 명시적으로 모델링하고 보류 사례로 평가한 보고는 우리가 검색한 범위에서 찾지 못했다.

본 연구는 사람의 복제가 아니라, 남아 있는 기록과 검토된 기억의 범위에서 **수정 가능한 판단 가설**을 만드는 것을 목표로 한다. 이를 위해 (i) 준비도·연결·일치를 분리해 보고하는 원칙, (ii) 입력을 가상으로 바꿔 출력 의존을 재는 연결 검사, (iii) 판단 정책 포착과 이양 규칙, (iv) 자연 발생 판단 사례와 기록 오염 격리, (v) 보류 예측·재검사 상한·블라인드 구별·일반 LLM 대조군을 결합한 평가 프로토콜을 제안한다.

단일 사용자(N=1) 로컬 시스템에서 기록 오염 324건 격리, 연결 검사의 선택 전파 6/8($p \approx 0.004$, 소형 로컬 모델), 말투 교정(반말 비율 68%→100%, n=6)의 예비 관찰을 얻었다. 같은 원칙을 공개 인물 11명에 적용해 78문항 질문은행의 근거 커버리지(0~39문항)를 측정했다. 판단 사례가 부족해 본인 일치는 아직 측정하지 못했으며, 본 원고는 사전 등록 가능한 연구 설계로서 제시한다.

주제어 디지털 트윈, 개인 아바타, 판단 정책 포착, 보류 평가, 기억 오염, 페르소나 시뮬레이션, AI 윤리

Abstract

LLM-based digital twins of individuals are typically evaluated on survey items or conversational plausibility, and individual-level prediction remains weak. We argue that a judgment-delegating avatar should instead be evaluated on whether it reproduces the owner's *held-out* decisions and whether it defers when it cannot. We propose (i) a reporting principle that separates readiness, causal linkage, and agreement (sync); (ii) a linkage test that injects counterfactual criteria without touching stored data; (iii) explicit judgment-policy capture with deferral rules; (iv) naturally occurring decision pairs with contamination quarantine; and (v) a protocol combining held-out prediction, a test–retest ceiling, blind discrimination, and an uninformed-LLM control. In a single-user (N=1) local system we observed 324 quarantined contaminated utterances, criterion propagation in 6/8 linkage probes ($p \approx 0.004$, small local model), and a register correction (informal-speech rate 68%→100%, n=6). Applying the same principles to 11 public figures, we measured evidence coverage on a 78-item question bank (0–39 items). Agreement with the owner's own decisions has not yet been measured; we present this work as a pre-registrable study design.

Keywords digital twin, personal avatar, judgment policy capturing, held-out evaluation, memory contamination, persona simulation

1. 서론

목표는 사용자가 없어도 사용자와 같은 생각·판단·가치·윤리 기준으로 일반·업무 상황의 결정을 내리고, 그 결론을 사용자의 얼굴과 목소리로 전달하는 아바타다. 성공 기준은 "지식이 많다"가 아니라 "내가 직접 판단했을 때와 같은 결정을 내리는가"이다. "나와 똑같다"는 철학적으로 증명할 수 없으므로(동일성이 아니라 연속성의 정도[23]) 목표를 **시험한 영역에서 내 답과 구별되지 않는 정도**로 정의한다.

이 정의는 흔한 착각 하나를 막는다. 아바타에 넣은 정보의 양, 지식 그래프의 크기, 설정 화면의 완성도는 *준비도*일 뿐 일치가 아니다. 본 연구는 세 용어를 구분한다. **기초 지식**은 입력된 사실·기준의 양과 질, **연결**은 그 입력이 실제로 출력을 바꾸는지, **일치(sync)**는 학습에 쓰지 않은 본인의 실제 판단과 아바타의 판단이 같은 비율이다. 일치는 마지막 정의로만 말한다.

표 1. 연구 질문과 대응 측정

번호	연구 질문	대응하는 측정
RQ1	내가 넣은 기준·사실은 아바타의 답을 실제로 바꾸는가(인과적 연결)?	연결 검사: 가상 기준 개입 후 선택 전파·표현 불변·모름의 정직성
RQ2	판단 정책을 명시 모델로 포착하면 보류한 내 판단과의 일치가 일반 LLM·RAG·요약 방식보다 높은가?	보류 예측 일치율(조건 B0~B4 쌍대 비교)
RQ3	그 일치는 내 자기 일관성(재검사)의 몇 %이고, 지인이 구별할 수 있는가?	재검사 천장 정규화, 블라인드 구별 정확도
RQ4	아바타가 "내 기준으로 확신하지 못하는 경우"를 알아채 본인에게 넘길 수 있는가?	확신도 보정, 위험–커버리지 곡선
RQ5	개인 기록의 오염(환각·에코·주변소리)을 거르면 입력의 질이 어떻게 달라지는가?	격리 건수·유형, 필터 전후 입력 비교
RQ6	이 과정을 안전장치(AI 표시·승인·중지) 아래에서 운영할 수 있는가?	운영 체크리스트(정성)
RQ7	이름을 알려 주지 않아도 사람들이 페르소나의 답만 보고 "그 사람 같다"고 알아보는가? 그 판단은 이름만 준 일반 LLM보다 나은가?	12절: 이름을 가린 인물 식별(블라인드), 보류 기록 복원, 기록 없음 정직성
RQ8	(성장) 본인의 교정 피드백이 쌓일수록 그 사람의 눈이 발전하는가? 즉 피드백 라운드가 늘수록 고정된 보류 사례의 일치가 오르고 이양이 줄어드는가?	피드백 라운드별 학습 곡선(보류 집합 고정, 누출 규칙 12절), 결정 유형별 향상폭과 정체 지점
RQ9	(전수) 다른 사람이 아바타의 판단과 근거를 참고하면 그 사람의 판단에 더 가까워지는가?	참고 있음/없음 조건에서 후임자·동료 답과 본인 답의 일치 비교(동의한 참여자, 설계만)

본 원고의 기여는 다음과 같다(모두 검증 전이며, 주장 강도는 표 4에 따로 표시했다).

1. **보고 원칙.** 기초 지식(준비도)·연결·일치(sync)를 분리하고, 일치는 학습에 쓰지 않은 본인 판단과의 비교로만 보고한다.
2. **연결 검사.** 저장 데이터를 바꾸지 않고 가상 기준을 주입해, LLM 판정자 없이 글자 파싱과 이항검정으로 입력→출력 의존을 잰다.
3. **판단 정책 포착과 이양.** 단서→기준·가중치→예외→결정·확신도→이양으로 이어지는 명시 정책을 판단 대리의 단위로 삼는다.

4. **판단 데이터와 오염 격리.** "직전 AI 발화 → 내 답" 짝을 자연 발생 판단 사례로 쓰고, 음성 기록의 환각·에코를 정량 격리한다.
5. **평가 프로토콜.** 보류 예측·재검사 상한·블라인드 구별·일반 LLM 대조군을 한 프로토콜에 결합하고, 직접 평가가 불가능한 인물에는 층별 식별 평가를 적용한다.

본 원고의 기여(검증 전)는 표 4에 주장 강도와 함께 정리했다. C1·C2·C4는 구현과 예비 자료가 있고, C3·C5는 설계 단계이며, C6(얼굴·목소리 통합)은 시스템 기여로 개별 요소의 새로움은 약하다.

2. 관련 연구

표 2는 원문(초록·본문)을 직접 확인한 연구를 위주로 정리했다. 수치는 각 논문이 보고한 값이며, 정답률이 아니라 각 연구가 정한 기준(예: 본인 재응답 대비)에 따른다. 평가의 흐름은 "사람처럼 보이는가"[2,3]에서 "개인을 맞히는가"[1,5]로 옮겨 가고 있으나, 개인 수준 결과는 제한적이다. 질문 500개 이상으로 만든 트윈도 사람 응답과의 상관이 평균 r=0.20에 그쳤다는 메타 분석[6]과, 평균은 재현해도 누가 평균에서 벗어나는지는 거의 맞히지 못한다는 분석[5]이 대표적이다.

표 2. 가까운 선행 연구

연구	입력·방법	주요 결과	본 연구가 보는 한계
Park 외, 2024(v3 2026) arXiv:2411.10109	1,052명의 2시간 인터뷰·설문을 넣은 LLM 에이전트	인터뷰 83%, 설문 82%, 결합 86%, 인구통계만 74%	질문이 설문 문항 중심. 개인 판단 정책·이양 조건 없음. 일치의 천장(재검사)은 있으나 지인 구별은 없음
Shi 외, 2025 (IMPersona) arXiv:2504.04332	개인 메시지 + 파인튜닝 + 계층 기억 검색	44.44%가 사람으로 판정 (프롬프트만 25%)	말투·대화 위주. 판단의 이유·기준은 평가하지 않음. 오용(사기) 위험을 함께 지적
Guo 외, 2026 (Individual Turing Test) arXiv:2603.01289	한 명의 10년 치 메시지로 파인튜닝·RAG·기억·하이브리드 비교	지인 심판이면 통과 못 함. 파인튜닝은 말투, 검색·기억은 의견·선호에 유리	단일 사례, 자동 언어 지표. 판단 일치를 보류 사례로 재지 않음
Toubia 외, 2025 (Twin-2K-500) arXiv:2505.17479	2,058명·500문항 설문 데이터	재검사 정확도 기준선을 만드는 설계 제시	데이터셋 중심. 판단 정책 모델링은 범위 밖
Wang·Hunt·Tang·Joseph, 2026 arXiv:2609.07987	디지털 트윈이 인간 측정을 대체할 수 있는 조건 분석	평균은 재현해도 누가 평균에서 벗어나는지는 거의 못 맞힘. 행동 충실도는 대체의 필요·충분 조건이 아님	진단 연구. 개인 이탈을 맞히는 방법은 제시하지 않음
Li 외, 2025 (BehaviorChain) arXiv:2502.14642	1,001개 페르소나의 이력·프로필과 15,846개 연속 행동을 사용	최신 모델도 연속적인 사람 행동을 정확히 모사하는 데 어려움을 보임	공개 페르소나 기반 벤치마크. 실제 한 개인의 가치·판단 근거와 재검사 상한은 다루지 않음
Du 외, 2025 (TwinVoice) arXiv:2510.25536	사회·대인·서사 맥락의 페르소나 시뮬레이션	고급 모델도 특히 문체와 기억 회수에서 사람 기준에 못 미침	생성형 평가는 LLM 판정 의존성이 남음. 개인의 실제 결정과 이유를 보류 사례로 맞히는 평가는 범위 밖
Peng·Gui 외, 2025 (Funhouse Mirrors) arXiv:2509.19088	사전등록 연구 19개·결과 164개 메타 분석	질문 500개 이상 트윈도 평균 r=0.20, 기본 LLM보다 "조금" 나음. 왜곡 5종(개별화 부족·고정관념·표상 편향·이념 편향·과잉 합리성)	왜곡을 진단하지만 줄이는 입력 구조(판단 정책)는 제안하지 않음
Wang 외, 2026 (LifeMem) arXiv:2608.19621	생애 사건 검색 + 개인별 파라메트릭 메모리	고정 프로필의 "정체성 본질주의"를 줄임	사건·기억 축. 판단 기준·예외의 명시 모델은 없음
He 외, 2026 (PERSONAJUDGE) arXiv:2607.05742	평가자 32명·판단 4,200건, 개인 평가자 시뮬레이션	"왜 그렇게 판단했는지" 회고적 추론 기록이 가장 큰 이득(최대 + 9.9%p), 인터페이스 텔레메트리는 해가 되기도 함	판단 근거의 효과를 보이지만 기준·가중치를 명시 정책으로 만들지는 않음

연구	입력·방법	주요 결과	본 연구가 보는 한계
Wei 외, 2025 (Second Me) arXiv:2503.08102	L0 원본(RAG) / L1 자연어 요약 / L2 개인 모델(Qwen2.5-7B, SFT·DPO)	1인칭 기억 QA 0.96, 제3자 0.76, 컨텍스트 보강 0.85, 비평 0.86(만점 대비)	평가 대상 1명·LLM 채점, 제3자 질문에 약함, 본문 내 모순, 판단 대리가 아니라 "컨텍스트 제공자"

판단 근거를 넣으면 개인 판단 재현이 좋아진다는 증거는 있다. 회고적 추론 기록이 최대 +9.9%p 이득을 냈다[8]. 그러나 이를 기준·가중치·예외를 가진 재사용 가능한 정책으로 만들지는 않는다. 개인 가치를 대화로 끌어내 보상모델로 만드는 연구[18,19]는 있지만, 판단 대리 아바타의 결정을 이양 조건까지 포함한 명시 정책으로 만들어 보류 사례로 평가한 연구는 찾지 못했다. 판단을 명시 모델로 만들면 일관성 덕분에 본인보다 안정적일 수 있다는 고전적 결과[21,22]가 이 방향의 이론적 근거다.

기록 쓰기 시점의 오염 방지[13,14]와 음성 인식의 비음성 환각[15]은 각각 연구가 있다. 그러나 개인 음성 기록의 환각·에코·주변 소리가 개인 기억과 판단 사례로 들어가는 문제를 정량 보고한 연구는 찾지 못했다. 빅테크의 개인 에이전트[30,31]는 닮음을 측정 대상으로 삼지 않으며, 개인 지식의 디지털화("Avatar")와 대리 행동(에이전트)을 분리한 Microsoft의 Digital Me[30]가 구조상 가장 가깝다.

표 3. 선행 연구의 빈틈

번호	빈틈
G1	개인 수준 예측이 약하다. 평균은 맞춰도 "이 사람이 평균에서 어떻게 벗어나는지"를 못 맞힌다.
G2	입력이 사실·말투·설문 응답 중심이다. 개인의 가치 정의를 대화로 끌어내 보상모델로 만드는 연구는 있으나(Blair 외, 30명), 판단 대리 아바타의 결정을 기준·가중치·예외·이양 조건을 명시한 정책으로 만들어 보류 사례 일치로 평가한 연구는 검색(S1·S8)에서 찾지 못했다.
G3	판단 근거를 넣으면 좋아진다는 증거는 있으나, 그 근거를 재사용 가능한 정책으로 구조화하지는 않는다.
G4	평가 척도가 연구마다 달라 비교가 어렵다. 보류 판단 사례·일반 LLM 대조군·재검사 상한·블라인드 구별을 한 프로토콜에서 함께 적용한 보고는 우리가 확인한 범위에서 드물다.
G5	대표적 오픈소스 개인 모델은 평가 대상이 1명, 채점이 LLM이고, 제3자가 물을 때 크게 떨어지며 판단 대리가 아닌 컨텍스트 제공자다.
G6	저장 시점 오염 방지(ConsistencyGate, MemGuard)와 Whisper의 비음성 환각(Barański 외)은 각각 연구가 있다. 그러나 개인 음성 기록의 환각·에코·주변소리가 개인 기억·판단 사례로 들어가는 문제를 정량 보고하고 거르는 연구는 검색(S5·S9)에서 찾지 못했다.
G7	넣은 정보가 출력을 실제로 바꾸는지를 개입 실험으로 확인한 보고를 찾지 못했다(준비도·입력량으로 갈음하는 경향).
G8	동의·AI 표시·중지 같은 안전장치가 평가 설계와 분리돼 있다.
G9	그럴듯한 대화·말투와 연속 행동·판단 예측은 다르며, 기억 회수·의견 일관성·문체를 한 점수로 합치면 실패 원인을 알 수 없다.

G2·G4·G6·G7은 "찾지 못했다"는 부재 주장이다. 2026-10-11에 단일 검색 엔진·영어 쿼리로 1차 검색(9개 쿼리)을 했으며 체계적 문헌고찰(PRISMA)이 아니다. 따라서 부재 주장은 가설이다.

3. 연구의 기여와 접근

표 4. 기여 후보와 주장 강도

기여	내용	의미(기존 대비)
C0	"그 사람의 눈으로 발전"의 조작적 정의: 포착 → 확장 → 성장 → 전수	재현(같은 답을 하는가)에서 발전(새 상황에서 작동하고 피드백으로 나아지는가)으로 평가 대상을 옮긴다
C1	기초 지식 · 연결 · 일치(sync) 용어 분리와 보고 원칙	입력량·준비도를 일치처럼 보고하는 오류를 막는다. 일치는 학습에 안 쓴 내 답과의 비교로만 말한다
C2	연결 검사: 가상 기준 개입 → A/B 강제 선택의 전파·불변	LLM 판정자 없이 글자 파싱과 이항검정으로 입력→출력 의존을 잰다(G7)
C3	판단 정책 포착 기반 설계(단서→기준·가중치·예외→결정·확신도→이양)	판단을 명시 정책으로 만들어 일관성과 이양 조건을 얻는다(G2·G3)

기여	내용	의미(기존 대비)
C4	자연 발생 판단 사례 짝(직전 AI 발화 → 내 답)과 오염 필터링 파이프라인	추가 설문 없이 판단 사례·시험 데이터를 얻고, 오염을 정량으로 보고한다(G6)
C5	일치 측정 프로토콜: 보류 + 일반 LLM 대조군 + 재검사 상한 + 블라인드 + 개인 이탈, 그리고 능력별 분해	보류 판단 정확도(연속 판단 포함), 기억 회수, 의견 일관성, 말투·문체를 따로 보고 실패 원인을 감춘 단일 점수를 피한다(G4·G9)
C6	판단 → 얼굴·목소리 전달 통합(3D 얼굴 복원을 리그 아바타에 이식, 승인 게이트·AI 표시)	시스템 기여. 개별 구성요소의 새로움은 약하다

주장 강도: C1·C2·C4는 구현·예비 자료가 있고, C3·C5는 설계 단계이며 일치 결과가 없다. 새로움은 모두 "우리가 아는 범위"이며 검증 전이다.

방법론적 비유: 역공학. 소프트웨어 역공학은 실행 흔적을 근거로 기능 가설을 세우고 입력을 바꿔 분기를 시험하며 증거를 남긴다. 본 연구는 이 증거 중심 태도를 개인 판단에 옮긴다. 관찰 대상은 상황·선택지·실제 선택·이유·포기한 대안·예외·확신도이고, 복원 대상은 단서→기준·가중치→예외→결정→이양으로 이어지는 판단 정책 가설이다. 다만 사람에게는 원본 코드가 없고 맥락·감정·새 정보에 따라 판단이 달라지므로, 함수·호출 그래프 복원이나 완전 호환 재구성 같은 가정은 명시적으로 배제한다. 산출물은 "사람의 원본"이 아니라 증거·범위·불확실성이 표시된 판단 정책 모델이다.

4. 시스템

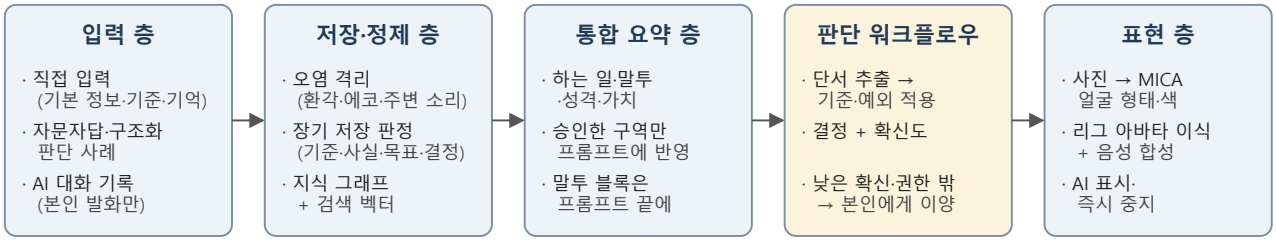


그림 1. 시스템 구성. 입력은 본인이 쓴 것만 장기 기억 후보가 되고, 승인한 요약만 프롬프트에 들어간다.

- 입력 층: 직접 입력(기본 정보·기준·핵심 기억), 자문자답, 아바타 대화(타이핑만 자동 사실 후보), Claude Code·Codex 대화 기록(백업 후 내가 쓴 글만).
- 저장·정제 층: 지식 그래프(KG)와 검색 벡터. 저장 직전 환각·에코·주변소리·반복·내용없음을 격리(복원 가능). 로컬 모델이 기준·사실·목표·결정만 장기 저장하고 지시·반응·질문·잡담은 제외(선호 표지가 뚜렷하면 모델이 놓쳐도 유지).
- 통합 요약 층: 하는 일(LLM 초안), 말투(타이핑 표본 통계), 성격(직접 입력), 가치(기준·자문자답). 승인한 구역만 프롬프트에 들어가고 말투 블록은 프롬프트 끝에 둔다.
- 판단 워크플로우: ① 사례 입력 → ② 단서 추출(비용·위험·정확성·일정·사람) → ③ 내 기준·가중치·예외와 비슷한 과거 결정 적용 → ④ 결정과 확신도를 내 말투로 → ⑤ 확신이 낮거나 낯선 유형이거나 권한 밖이면 본인에게 이양 → ⑥ 결론을 얼굴·목소리로 전달. (①~⑤ 중 ③⑤는 설계 단계)
- 연결 검사: 실제 아바타와 같은 경로로 프롬프트를 만들되 DB를 바꾸지 않고(what-if) 가상 기준을 주입. 판정은 A/B 글자 파싱과 이항검정이며, 판독 불가·빈 응답이 25%를 넘으면 "측정 실패"로 표시한다.

- 표현 층: 사진 몇 장 → MICA가 FLAME 기반 얼굴 형태와 사진 투영 색을 추정 → 18개 기준점 정렬과 조밀 표면 대응으로 리그(모프타겟·스켈레톤)가 있는 아바타에 형태 이식 → UV 텍스처로 색 반영. 형태·텍스처 가중치로 MICA 반영 정도를 조절하고, 입·눈 변형은 FLAME 재사용으로 만든다.

표 5는 일치를 막는 요인별로 이 프로젝트가 하는 일과 현재 상태를 정리한 것이다. 상태는 솔직하게 적었다. "구현됨(미측정)"은 코드와 화면이 있으나 효과를 재지 않았다는 뜻이다.

표 5. 문제 → 해결 방식 → 상태

일치를 막는 문제	하는 일	상태
내가 무엇을 중시하고 어떻게 고르는지 입력이 없다(입력이 지식뿐)	자문자답으로 판단·기준·예외를 직접 받는다(주제+ 관점 조합으로 질문 생성). 이어서 판단 정책 포착으로 사례→기준·가중치·예외를 명시 모델화	구현됨(미측정)
정책 모델이 아직 없다	결정 유형 하나를 골라 사례를 수집하고 기준·가중치·예외를 명시 모델로 만든 뒤 결정과 확신도를 낸다	설계만
가치·신념·선호는 지식과 다르게 재야 한다	심리학 구성개념(기본 가치, 도덕 직관, 개인 구성개념, 선호 강도, 이유 사슬)을 질문 틀로 사용	설계만
기록이 오염돼 있다(음성 환각·에코·주변소리)	저장 직전 판별해 격리(삭제 아님, 복원 가능), 아바타 답변은 내 사실로 학습하지 않음	측정됨
어떤 기록을 오래 남길지 모른다	Claude Code·Codex 대화를 원본 백업 후 내가 쓴 글만 추출, 규칙 필터 + 로컬 모델로 종류(기준·사실·목표·결정만 KG) 판정	측정됨
요약이 내 생각이 아닌데 내 말처럼 들어간다	승인한 구역만 프롬프트에 반영하고 직접 입력을 자동 추출보다 우선. 자동 사실은 서로 다른 발언에서 2회 확인돼야 반영	구현됨(미측정)
넣은 정보가 실제로 답을 바꾸는지 모른다	연결 검사: DB를 건드리지 않고 가상 기준을 주입해 A/B 선택의 전파·표현 불변·모름의 정직성 확인	측정됨
입력량·준비도를 일치로 착각한다	준비도 퍼센트를 일치라 부르지 않고, 일치는 "측정 불가/가능"을 지표별로 표시	구현됨(미측정)
말투·호칭이 상황마다 다르다	말투 블록을 프롬프트 맨 끝에 두고 반말은 채팅·친한 사람에게만, 그 외는 존댓말	측정됨
시험 데이터가 없다(학습에 안 쓴 내 답)	직전 AI 발화→내 답 짝을 자연 수집(2,879건)하고 일부를 보류	구현됨(미측정)
내 자기 일관성보다 정확해질 수 없다(상한 모름)	같은 질문을 간격을 두고 다시 답해 (아바타 vs 나)÷(나1 vs 나2)로 정규화	미착수
내 답과 구별되는지 모른다	섞어 놓은 내 답과 아바타 답을 본인·지인이 맞히게 함	미착수
일반 LLM이 이미 잘 맞히는지 모른다	프로필 없는 기본 LLM과 인구통계만 준 LLM을 대조군으로 같은 문항에 적용	미착수
평균은 맞히고 내 특이점은 못 맞힌다	일반 LLM과 내 답이 갈리는 문항만 따로 평가	미착수
확신이 낮은데 그럴듯하게 답한다	확신이 낮거나 처음 보는 유형이거나 권한 밖이면 본인에게 넘기는 조건	설계만
시간이 지나 내가 바뀌거나 기억이 낡는다	출처·확신도·재확인 주기 열, 오래되거나 자기보고와 행동이 다른 항목 재확인	설계만
결론을 내 얼굴·목소리로 전달해야 한다	사진 몇 장→MICA 얼굴 형태·색→리그 아바타(Streamoji) 이식, 형태·텍스처 가중치 조절, XTTS 음성	구현됨(미측정)
오용·동의 문제	내가 승인한 것만 입력, AI 아바타 표시·즉시 중지 기준, 외부 행동은 승인 시스템 없이는 불가	설계만

5. 평가 프로토콜 (사전 등록 형식 초안)

데이터. 판단 사례 D = {상황, 단서, 내 결정, 이유, 확신도}. 출처는 자문자답과 대화 기록의 판단 짝(직전 AI 발화 → 내 답)이다. 시간순으로 정책 구성용과 보류용(예: 30%)으로 나누고, 시험 문항이

정책 작성 사례와 겹치지 않게 시험 사례를 먼저 봉인한다.

표 6. 비교 조건(같은 모델·같은 프롬프트 예산)

조건	구성(같은 모델·같은 프롬프트 예산)
B0	일반 LLM(내 정보 없음)
B1	기본 정보·인구통계만
B2	KG 검색(RAG)
B3	RAG + 승인한 통합 요약 + 말투
B4	B3 + 판단 정책(제안 방식) + 이양 규칙

표 7. 지표

지표	정의
M1 보류 일치율	보류 사례에서 결정이 내 결정과 같은 비율, Wilson 95% 구간, 조건 간 쌍대 비교(McNemar)
M2 재검사 천장	같은 질문을 간격을 두고 다시 답해 (아바타 vs 나)÷(나1 vs 나2)
M3 블라인드 구별 (생존 대상 한정)	섞인 내 답/아바타 답을 본인·지인이 맞히는 정확도
M4 개인 이탈	B0과 내 답이 갈리는 문항에서 아바타가 내 쪽을 택한 비율
M5 확신도 보정	확신도별 일치율, 이양 기준별 위험–커버리지
M6 연결	연결 검사의 선택 전파·표현 불변·모름의 정직성

- 표본 크기: 정확도 50% 가정 시 95% 구간 반폭이 n=30이면 약 ±18%p, n=100이면 약 ±10%p. 조건 간 차이를 보려면 n≥100을 목표로 한다.
- 보고 원칙: 준비도·입력량·KG 크기는 일치로 보고하지 않는다. 근거 커버리지·모순·최신성은 "근거의 질" 지표로 따로 둔다.
- 대조군 필수: 프로필 없는 기본 LLM 대비 증분이 핵심 결과이다(Peng 외).
- 일반화: 현재 N=1이므로 사례 연구로 보고한다. 일반화 주장을 하려면 참가자를 추가해야 한다(논문까지 남은 일 참고).

5.1 직접 평가가 불가능한 대상: 이름을 가린 인물 식별

고인·역사 인물은 새 답을 받을 수 없으므로 일치(sync)를 주장하지 않는다. 대신 "그 사람이 맞다"는 주장을 충실성(기록과 맞는가), 구별성(다른 사람과 구별되는가), 승인(아는 사람이 그럴듯하다고 보는가), 일치(본인과 같은가)로 나누어 층별로 보고하고, 하나의 점수로 합치지 않는다. 핵심 방법은 이름·호칭·고유명사를 지운 답을 보고 평가자가 후보 k명 중 누구인지 고르는 블라인드 식별이다(우연 수준 1/k). 유명인은 일반 LLM이 이미 알고 있으므로, 이름만 준 LLM(B0)과 수집 자료 검색(B1)의 증분만을 자료의 기여로 보고한다.

표 8. 인물 식별 평가의 층(E1~E8)

층	묻는 것	적용 대상	상태
E1 이름을 가린 인물 식별	이름 없이 답만 보고 누구의 답인지 알아보는가	고인·역사 인물 포함 전원(자료가 충분한 인물만)	구현됨(미측정)
E2 실제 발언과의 구별	아바타 답과 실제 인용을 구별하는가	본인 발언이 충분한 인물	설계만
E3 보류 기록 복원	감춘 실제 발언과 같은 입장으로 답하는가	본인 발언이 충분한 인물	설계만
E4 기록 없음 정직성	기록에 없는 질문에 "찾지 못했다"고 답하는가	전원	구현됨(미측정)
E5 출처 충실성	답의 사실 주장이 제시한 출처 문단에 뒷받침되는가	전원	구현됨(미측정)
E6 전문가 검수	시대착오·사료에 없는 단정이 있는가	역사 인물	설계만
E7 지인·유족 승인	아는 사람이 근거별로 맞다/틀렸다/고친다고 하는가	서비스 단계	구현됨(미측정)
E8 본인 일치	본인의 보류 판단과 같은가	생존자 본인(본 연구 N=1)	설계만

사전 판정 기준(결과를 본 뒤 바꾸지 않음): E1 정확도 95% 구간 하한이 1/k를 넘을 때만 "구별 가능", B1이 B0보다 쌍대 검정에서 유의하게 높을 때만 "수집 자료가 기여했다"고 쓴다.

6. 예비 결과

표 9의 모든 항목은 일치(sync)가 아니라 준비도·연결·데이터 품질에 관한 예비 관찰이다.

표 9. 현재까지의 예비 관찰 (N=1)

항목	값	설계·표본	한계
연결 검사: 선택 전파	8개 중 6개가 주입한 기준을 따라 바뀜 (이항검정, 우연 25% 가정, p≈0.004)	합성 딜레마 4개 × 방향 2, gemma4:e2b 로컬 모델, 한 문항을 세 번 물어 두 번 다 규칙을 따를 때 전파로 판정	소표본, 단일 소형 모델, 합성 상황. 정확↔일정 상황은 반대 기준을 따르지 않음
연결 검사: 표현 불변	8개 중 7개 일관	같은 선택지 순서를 바꿔 물음	약한 검사
연결 검사: 모름의 정직성	8개 중 8개	알 수 없는 질문에 모른다고 답하는지(문구 규칙)	약한 검사, 규칙 기반 판정
말투 교정 A/B	반말 68%→100%, 평균 204→78자, 상담원 표현 0	같은 질문 6개에 통합 요약 유무 비교	n=6. 통명스러운 답 1건 → 반말은 채팅·친한 사람에게만으로 규칙 수정
기록 오염 정리	사용자 발언 324건 격리(환각 184·내용없음 68·주변소리 32·반복 22·에코 9·실험 9), 아바타 답변 노드 427개 제외, 노드 2,632→1,881, 벡터 1,066→319	저장 데이터 전수 정리, 백업 후 실행, 격리는 삭제가 아님	규칙·임계값(20어절)은 내 타이핑 기준선에서 정함. 분류 정확도 검증 전
대화 기록 선별	Claude Code 58세션에서 내가 쓴 메시지 약 2,900건(중복 제거 후 약 2,300건), 규칙만으로 오래 남길 만한 것 약 24%. 판단 짝 2,879건. Codex 218세션 4,865건 분류 대기	로컬 모델 분류 정확도 약 70% (선호 표지 규칙 병행)	라벨 정확도·판단 포함 비율 미평가
일치(sync)	측정 불가	판단 사례(자문자답)가 부족하고 재검사·블라인드 수집 기능이 없음	—
3D 얼굴 이식	정량 평가 없음. 사용자 육안 평가 "좋아졌어"(미완결 의견), 처리 시간 +30~50초(UV 텍스처 굽기)	MICA → Streamoji, 형태·텍스처·강도 슬라이더	정량 지표·참가자 평가 없음
판정 문구 수정 효과	마르쿠스: 본인 문단 932개인데 확인된 답 0건 → 33건. 기존 문구가 "본인의 명시적인 답"만 인정해 자기 자신에게 쓴 글(2인칭, 명상록)을 거부한 것이 원인이었다	같은 문단 16개에 문구 2개 × 모델 2개를 적용해 비교. 기존 문구는 YES 0건, 본인 저작용 문구는 YES 6건(작성자가 읽어 보니 명백한 오답 1~2건 포함)	16개 문단을 한 사람(작성자)이 확인했다. 정밀도·재현율 미측정. 자료 종류(편지·일기·강연)별 차이는 보지 않았다
프로필 신뢰도 상한	확인된 근거 0건인 마르쿠스의 프로필 신뢰도가 90~98, 근거 10건이던 버핏이 33~55로 거꾸로 나왔다 → 확인된 답 수로 상한을 두어 0건은 20 이하로 제한	기존 프로필 파일 2건에 상한을 적용해 전후 비교	상한 공식(25 + 12 × 답 수, 최대 90)은 임의로 정했고 보정 전이다. 이 숫자는 확신이 아니라 근거의 양을 뜻한다

6.1 공개 인물 11명의 근거 커버리지

같은 원칙을 공개 인물 11명(현대 인물 6명, 역사 인물 5명)에 적용했다. 인물마다 같은 질문 78개(13개 영역)를 두고, BM25로 후보 문단을 뽑은 뒤 로컬 모델 두 개가 "이 문단이 질문에 대한 본인의 말인가"를 판정했다. 찾은 근거는 본인 글(own)과 전기·보도(reported)로 나누고, 못 찾은 질문을 일반 지식·추정으로 채운 것은 "확인된 답"으로 세지 않았다(그림 2).

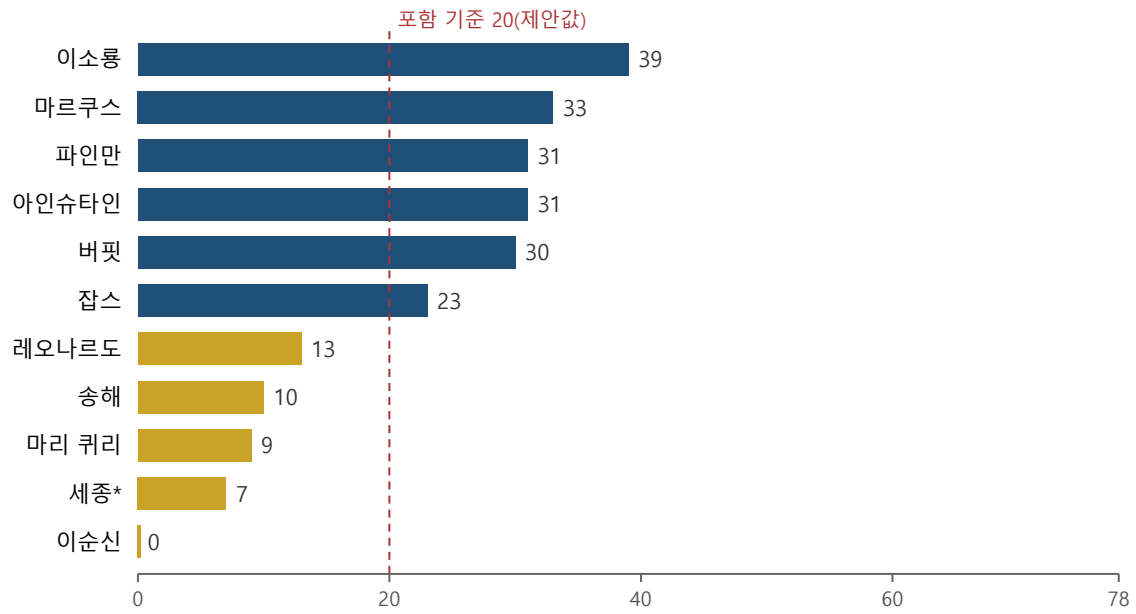


그림 2. 인물별로 수집 원문에서 확인된 답 수(2026-10-19 재판정). 짙은 막대는 블라인드 평가 포함 기준(20, 제안값) 이상. * 세종은 사람이 직접 작성한 근거라 재판정에서 제외.

두 가지 관찰이 중요하다. 첫째, 이 수치는 판정 설계에 매우 민감하다. 기존 판정 문구가 "본인의 명시적인 답"만 인정해 자기 자신에게 쓴 글(2인칭 독백인 『명상록』)을 거부했고, 문구를 본인 저작용으로 바꾸자 마르쿠스 아우렐리우스의 확인된 답이 0건에서 33건이 되었다. 둘째, 자료의 양과 확인된 답의 수는 비례하지 않는다. 이순신은 한문 원문(이충무공전서)을 포함해 문서 8건을 모았지만 0건이었는데, 한문을 판정 모델이 본인 답으로 알아보지 못한 것으로 추정한다(미확인). 확인된 답 수는 커버리지일 뿐 정확도가 아니며, 판정의 정밀도·재현율은 사람 검수 전이다. 자료 양이 4~115문서로 크게 달라 인물 간 비교나 평균은 의미가 없다.

인물 대화에서는 근거 검색이 "직접 답함"만 통과시키는 엄격한 판정 때문에 쉬운 일반 질문(예: 투자자에게 "좋은 기업은 어떻게 알아보나요?")에도 "자료에서 찾지 못했다"고 답하는 현상을 관찰했다. 질문을 해당 인물의 직책·분야 전문가 질문으로 바꿔 일반 지식 초안을 만든 뒤 인물 자료와 합성하고, 근거가 없으면 "분야 지식 보충 추정"으로 표시하도록 바꿨다. 효과는 아직 평가하지 않았다.

7. 논의

필요성. "외형·지식·행동이 모두 나와 똑같은 아바타"는 필요성 근거가 약하고 거부감이 크다. 반면 이 연구 안에 이미 있는 "내 판단 기준으로 1차 판단하고, 모르면 보류하는 대리인"은 부재 중 위임, 인수인계, 전문가 암묵지 보존처럼 필요가 분명하고 측정할 수 있다. 따라서 주 기여를 보류된 개인 판단의 재현 정도(RQ2)와, 재현이 실패할 때 스스로 보류하는 능력으로 고정한다. 고인 서비스는 애도에 미치는 영향에 합의가 없고 유족을 묶어 두는 구조가 될 수 있다는 비판[27]이 있어 논문 주장에서 제외한다.

거부감. 닮을수록 어색함이 먼저 보이는 문제[26], 내가 하지 않은 말이 내 이름으로 나가는 기만, 틀린 판단의 책임, 추정이 사실처럼 받아들여지는 혼동이 주요 지점이다. 이 연구가 이미 구현한 장치, 즉 근거 등급 구분·"기록에 없음" 보류·아는 사람의 리뷰는 원고에서 보조 기능처럼 보이지만, 수용성 관점에서는 가장 강한 차별점이다.

범용 LLM 대비. 범용 LLM도 "그 인물처럼 말하기"를 해 준다. 예상되는 한계는 출처 없는 지어낸 일화, 기록이 없는 질문에도 아는 척, 교과서 이미지로의 평균화, 현대 가치의 투영, 대화마다 바뀌는

입장, 그리고 틀렸을 때 무엇을 고칠지 알 수 없다는 점이다. 다만 이것은 아직 가능성이며, 세종의 확인된 근거는 7개뿐이라 포함 기준에 걸린다. 자료 보강 후 출처 충실성(E5)과 기록 없음 정직성(E4)에서 B0와 비교해야만 "낫다"고 말할 수 있다.

암묵지의 경계. 말로 꺼낼 수 있는 기준·예외·사례는 재현될 가능성이 있지만, 말로 다 할 수 없는 지식[25], 곧 현장 단서를 알아보는 지각적 판단과 새 상황에서 기준을 고쳐 가는 능력은 기록에서 복원하기 어렵다. 그래서 주장은 "대체"가 아니라 "그 사람 기준의 1차 판단 + 모르면 보류"로 한정하고, 결정 유형별 일치율과 실패 사례로 재현 가능 영역의 경계를 보여 주는 것을 기여로 삼는다.

8. 한계와 윤리

- 단일 사용자(N=1) 사례다. 일반화하지 않는다.
- 연결 검사는 소형 로컬 모델 하나와 합성 딜레마 4개로 했다. 큰 모델·실제 사례에서 재현이 필요하다.
- 자기보고는 부정확할 수 있다(Nisbett & Wilson, 1977). 말한 가치와 실제 선택의 불일치를 표시하는 절차는 설계 단계다.
- 자동 분류(약 70%)와 자동 사실 추출은 오류가 있다. 근거를 함께 보여 주고 사용자가 고칠 수 있게 한다.
- 얼굴·목소리는 오용 위험이 크다. 내가 나를 쓰는 동의는 단순하지만 AI임을 밝히고 내가 즉시 중지할 수 있어야 한다. 외부 공유 시 AI 생성 표시 의무가 걸릴 수 있다(EU AI Act 제50조, 한국 AI 기본법: 요약 수준 확인, 원문 재확인 필요).
- 현재 외부 메시지 발송·결제 같은 행동을 실행하는 승인 시스템은 연결돼 있지 않다.
- 대화 기록에는 제3자 정보가 섞일 수 있다. 연구 공개 시 비식별화와 동의 절차가 필요하다.
- 공개 인물 페르소나: 질문은행의 "확인된 답 수"는 커버리지일 뿐 정확도가 아니며 판정(로컬 모델 두 개)의 정밀도·재현율은 사람 검수 전이다. 판정 문구 하나를 고치자 마르쿠스의 결과가 0건에서 33건이 되었으므로, 이 수치는 판정 설계에 민감하다. 일부 인물은 판정 중 모델 오류가 있었다.
- 공개 인물 페르소나는 N이 크지만 인물마다 자료 종류(자서전·편지·인터뷰·전기)와 양이 달라 인물 간 비교나 평균은 의미가 없다. 번역본·전기·보도에 담긴 발언은 원 발언과 다를 수 있다.
- 유명인은 일반 LLM이 이미 알고 있을 수 있어, 수집 자료의 기여는 이름만 준 LLM과의 증분으로만 말할 수 있다(12절). "그 사람이 맞다"는 단일 판정은 하지 않으며, 고인·역사 인물에게는 일치(sync)를 주장하지 않는다.
- 이용 범위 정책(텍스트만 / 역사 인물 / 가상 AI / 동의 필수 개인 아바타)은 법적 안전을 보장하지 않는다. 퍼블리시티권·초상권·AI 표시 의무는 법률 검토 전이며, 마리 퀴리처럼 분류가 불분명한 인물이 있다.

9. 결론과 향후 연구

본 원고는 판단 대리 아바타를 "얼마나 많이 아는가"가 아니라 "보류한 내 판단을 얼마나 맞히고, 모를 때 넘기는가"로 평가하자는 연구 설계다. 준비도·연결·일치를 분리하는 보고 원칙, 가상 기준 주입으로 입력→출력 의존을 재는 연결 검사, 기록 오염 격리와 근거 등급 표시는 구현했고 예비 관찰을 얻었다. 핵심 주장인 일치는 아직 측정 전이다. 다음 관문은 순서대로 (1) RQ2를 중심 주장으로 범위 동결과 사전 등록, (2) 학습 전에 봉인한 보류 시험셋(n≥100 목표), (3) 같은 사례에서 B0~B4 비교, (4) 블라인드 인간 판정·본인 재검사·라벨 검수, (5) 코드·프롬프트·분할 규칙·실패 사례를 담은 재현성 패

키지다. 1~3이 최소 실증 요건이며, 그 전까지는 결과 논문이 아니라 연구 설계로 제시하는 것이 정직하다.

참고문헌

1. J. S. Park et al. LLM Agents Grounded in Self-Reports Enable General-Purpose Simulation of Individuals. arXiv:2411.10109, 2024 (v3 2026).
2. Q. Shi et al. IMPersona: Evaluating Individual Level LM Impersonation. arXiv:2504.04332, 2025.
3. Guo et al. Individual Turing Test. arXiv:2603.01289, 2026.
4. O. Toubia, G. Gui, T. Peng, D. Merlau, A. Li, H. Chen. Twin-2K-500. arXiv:2505.17479, 2025.
5. Wang, Hunt, Tang, Joseph. When Can LLM Digital Twins Reduce Human Measurement? arXiv:2609.07987, 2026.
6. T. Peng, G. Gui et al. Digital Twins as Funhouse Mirrors: Five Key Distortions. arXiv:2509.19088, 2025.
7. Wang et al. Mitigating Identity Essentialism in LLM Agents with Longitudinal Life Trajectories (LifeMem). arXiv:2608.19621, 2026.
8. He et al. PERSONAJUDGE: Simulating Individual Human Preference Judgments. arXiv:2607.05742, 2026.
9. Wei et al. AI-native Memory 2.0: Second Me. arXiv:2503.08102, 2025.
10. Li, Xia, Yuan, Dong, Sha, Li, Sui. How Far are LLMs from Being Our Digital Twins? (BehaviorChain). arXiv:2502.14642, 2025.
11. Du et al. TwinVoice: A Multi-dimensional Benchmark Towards Digital Twins via LLM Persona Simulation. arXiv:2510.25536, 2025.
12. Du. Memory for Autonomous LLM Agents: Mechanisms, Evaluation, and Emerging Frontiers. arXiv:2603.07670, 2026.
13. Zhang, Li. ConsistencyGate: Preventing Memory Contamination in LLM Agents via Self-Consistency Admission Control. arXiv:2607.22962, 2026.
14. Ha et al. MemGuard: Preventing Memory Contamination in Long-Term Memory-Augmented LLMs. arXiv:2605.28009, 2026.
15. Barański et al. Investigation of Whisper ASR Hallucinations Induced by Non-Speech Audio. arXiv:2501.11378, 2025.
16. Li et al. PersonaConvBench: Towards Simulating Personalized Conversations. arXiv:2505.14106, 2025.
17. Xu et al. Toward Personalized LLM-Powered Agents: Foundations, Evaluation, and Future Directions. arXiv:2602.22680, 2026.
18. Blair, Larson, Law. Democratizing Reward Design for Personal and Representative Value-Alignment. arXiv:2410.22203, 2024.
19. Blair, Larson, Law. Reflective Verbal Reward Design for Pluralistic Alignment. arXiv:2506.17834, 2025.
20. Chan et al. Redefining Research Crowdsourcing: Incorporating Human Feedback with LLM-Powered Digital Twins. arXiv:2505.24004, 2025.
21. L. R. Goldberg. Man versus model of man. Psychological Bulletin 73(6), 1970.†
22. R. M. Dawes. The robust beauty of improper linear models in decision making. American Psychologist 34(7), 1979.†
23. D. Parfit. Reasons and Persons. Oxford University Press, 1984.†
24. R. E. Nisbett, T. D. Wilson. Telling more than we can know. Psychological Review 84(3), 1977.†
25. M. Polanyi. The Tacit Dimension. 1966.†
26. M. Mori. The Uncanny Valley. Energy 7(4), 1970.†
27. T. Hollanek, K. Nowaczyk-Basińska. Griefbots, Deadbots, Postmortem Avatars. Philosophy & Technology 37:63, 2024. doi:10.1007/s13347-024-00744-w.
28. W. Zielonka, T. Bolkart, J. Thies. Towards Metrical Reconstruction of Human Faces (MICA). ECCV 2022. arXiv:2204.06607.
29. T. Li, T. Bolkart, M. J. Black, H. Li, J. Romero. Learning a model of facial shape and expression from 4D scans (FLAME). ACM TOG 36(6), 2017.†
30. Microsoft Research. Digital Me (project page, 2016~). 2026-10-19 확인.
31. TechCrunch. OpenAI launches Dots, its bubbly agentic avatar. 2026-09-29.
32. 언론중재 및 피해구제 등에 관한 법률 제5조의2(사망자의 인격권 보호). 원문 확인 필요.
33. California AB 1836 (Civil Code § 3344.1 개정), 2025-01-01 시행.

† 서지 정보를 기억에 근거해 적었으므로 인용 전 재확인이 필요하다. 나머지는 arXiv 초록·본문, 기사 또는 프로젝트 페이지를 직접 확인했다(일부는 초록만 확인).